



中国科学技术大学
University of Science and Technology of China

基于电商用户行为大数据的消费转化漏斗与购买预测分析

亿级日志处理 · 转化漏斗 · 购买预测

小组成员：图力格尔，杨大权

报告人：杨大权

电商行为数据分析汇报

2026 年 5 月 31 日



- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化



研究问题

从问题到数据，再到模型和业务结论

- ▶ 电商平台记录了用户从浏览、加购到购买的完整消费路径。
- ▶ 用户行为日志天然具有经济含义：消费意愿、促销响应、品类偏好、品牌选择。
- ▶ 原始日志达到亿级规模，不能用简单表格汇总，必须先做分块读取和聚合。
- ▶ 分析围绕“哪里流失、什么卖得好、谁更可能转化”展开。

电商行为日志连接了用户路径与消费结果。

1. 三个月内浏览、加购、购买的总体行为结构如何？
2. 10 月、11 月、12 月之间是否存在促销季和年末消费差异？
3. 哪些品类、品牌和价格区间贡献了主要交易额？
4. 能否利用行为特征识别高购买倾向用户和高转化加购 session？

四个问题分别对应规模、时间变化、交易结构和购买预测。



数据与方法

从问题到数据，再到模型和业务结论

层面	指标	作用
规模 转化	浏览、加购、购买、金额 浏览到加购、浏览到购买、 加购到购买	衡量平台整体活跃和交易规模 判断用户在哪个环节流失
结构 预测	品类、品牌、价格区间 Precision、Recall、F1、Top- K/Lift	找到主要交易来源 识别潜在购买用户和高转化 session

指标设计从总体规模逐步下钻到用户和 session 层面。

1.77 亿

三个月行为日志

100 万

单个读取 chunk

22.7 分钟

本地处理耗时

3 个月

10-12 月窗口

项目	数值
数据来源	Kaggle 电商行为数据集
时间范围	2019-10 至 2019-12
文件形态	csv.gz / csv.zip
总记录数	177,493,621
分块大小	每块 1,000,000 行
本地处理耗时	约 22.7 分钟



- ▶ 事件口径：直接统计每条日志，用于浏览量、加购量、购买量和销售额。
- ▶ 用户口径：对 `user_id` 去重，用于漏斗和用户购买倾向识别。
- ▶ 全量事件统计保留 1.77 亿条日志的信息。
- ▶ 唯一用户漏斗采用 `user_id` 固定取模抽样估计，避免本地内存压力。
- ▶ 分析中明确区分“事件数”和“估计唯一用户数”，避免口径混用。

事件用于描述规模，用户用于描述转化，两类口径分开计算。

数据处理

- ▶ 压缩 CSV 分块读取
- ▶ 时间、价格、品类、品牌清洗
- ▶ 日、月、小时维度聚合
- ▶ 用户与 session 特征构造

建模分析

- ▶ 用户-月份特征表
- ▶ 购物车 session 转化样本
- ▶ 逻辑回归与规则基线
- ▶ TopK/Lift 与特征解释

原始日志先被压缩为聚合表和特征表，再进入图表与模型。

```
reader = pd.read_csv(file_path, usecols=usecols,
                     chunksize=1_000_000,
                     compression="infer")

for chunk in reader:
    chunk["event_time"] = pd.to_datetime(
        chunk["event_time"], utc=True, errors="coerce"
    )
    chunk["month"] = chunk["event_time"].dt.strftime("%Y-%m")
    chunk["is_purchase"] = (chunk["event_type"] == "purchase")
```

每次只处理 100 万行，保留聚合结果和用户抽样特征，不长期保存原始明细。

分块读取使本地环境可以处理亿级压缩日志。



行为结构

从问题到数据，再到模型和业务结论

三个月用户行为事件量



- ▶ 浏览：167,321,576 次
- ▶ 加购：7,350,209 次
- ▶ 购买：2,821,836 次
- ▶ 购买金额：849,329,221.91

浏览量占绝对多数，购买行为稀疏，后续分析重点应放在转化环节。

月份	浏览	加购	购买
2019-10	40,779,399	926,516	742,849
2019-11	63,556,110	3,028,930	916,939
2019-12	62,986,067	3,394,763	1,162,048

11 月和 12 月的流量与购买量明显高于 10 月，但流量增长并不自动等于转化效率提升。


促销季带来了规模增长，但需要结合转化率判断真实运营效果。

行为	峰值小时	峰值事件数
浏览	16 点	11,564,432
加购	8 点	495,343
购买	9 点	211,140

- ▶ 浏览更像信息搜索和比较。
- ▶ 加购与购买更接近明确消费动作。
- ▶ 推荐曝光、购物车提醒和支付激励可以分时段设计。


不同动作的高峰不完全一致，说明“浏览触达”和“支付转化”应分开运营。

三个月日度行为变化



日度曲线用于识别促销期和月末变化，避免只看三个月总量。

各月加购到购买转化率



- ▶ 10 月购买规模较小，但加购到购买比例较高。
- ▶ 11 月流量和加购明显放大，转化效率被摊薄。
- ▶ 12 月购买量继续上升，年末消费需求更强。


10 月转化率最高，11 月加购放大但转化被摊薄，12 月购买量继续上升。



转化漏斗

从问题到数据，再到模型和业务结论

转化漏斗估计用户规模



阶段	估计用户数	占比
浏览	7,853,880	100.00%
加购	1,711,640	21.79%
购买	1,045,680	13.31%

约 21.79% 的浏览用户进入加购，约 13.31% 最终购买。

- ▶ 浏览到加购：反映商品匹配、搜索推荐和详情页质量。
- ▶ 加购到购买：反映价格、促销、库存、配送和支付体验。
- ▶ 加购未购买用户已经表现出较强意向，是平台二次触达的重点对象。
- ▶ 促销期不应只看访问峰值，还要看购物车沉淀后的支付转化。


加购用户已接近购买决策，是转化分析的核心人群。



品类与品牌


从问题到数据，再到模型和业务结论

销售额最高的品类 Top 12



消费电子和家电相关品类贡献了主要销售额。

销售额最高的品牌 Top 12



Apple 与 Samsung 呈现不同结构：一个偏高客单价，一个偏广覆盖。



- ▶ 手机、灯具工具、耳机、钟表、电视和家电贡献主要交易额。
- ▶ Apple 购买次数低于 Samsung，但销售额更高，体现高客单价特征。
- ▶ Samsung 购买次数最高，说明其覆盖更广泛的交易需求。
- ▶ unknown 品类和品牌占比不低，实际业务中需要改进商品信息治理。

品牌销售额不能只看购买次数，客单价会显著改变排序。

价格区间	购买金额	金额占比
500-1000	268,103,353.39	31.57%
200-500	233,270,380.69	27.47%
1000-5000	194,988,617.34	22.96%
100-200	113,879,642.68	13.41%

中低价商品贡献交易频次，高价商品贡献销售额，需要分别管理。

500-1000 和 200-500 两个价格区间合计贡献接近六成销售额。



购买预测

从问题到数据，再到模型和业务结论

预测目标

以用户-月份为样本，预测用户当月是否发生购买。

输入特征

总行为次数、浏览次数、加购次数、会话数、活跃天数、浏览商品数、浏览品类数、浏览品牌数、平均价格、最高价格。

模型

使用 NumPy 实现逻辑回归，并对正样本设置权重以缓解类别不平衡。

用户-月份模型刻画购买倾向与行为信号之间的关系。



- ▶ 样本单位：用户-月份。
- ▶ 标签：当月是否至少发生一次购买。
- ▶ 特征：当月行为强度、会话数、活跃天数、商品/品类/品牌范围、价格偏好。
- ▶ 当前模型适合识别高购买倾向用户。
- ▶ 更严格的实时预测应使用“前期行为预测后期购买”的时间切分。

该模型输出的是当月购买倾向，不代表实时下单概率。


指标	数值
测试集样本	50,000
正样本比例	11.43%
Accuracy	89.95%
Precision	53.68%
Recall	85.49%
F1	0.659

购买预测模型混淆矩阵

	Pred 0	Pred 1
True 0	TN 40,105	FP 4,201
True 1	FN 826	TP 4,868

模型更擅长捞出潜在购买用户，Precision 不高但 Recall 达到 85.49%。

购买预测模型特征重要性



- ▶ 加购次数是最强购买意图信号。
- ▶ 总行为次数和会话数反映用户活跃程度。
- ▶ 浏览范围过宽可能意味着仍在比较，购买确定性下降。

加购次数是最强信号，说明购物车行为比单纯浏览更接近购买意向。

用户信号	可采取动作
多次加购未购买 浏览范围广但未加购 高价商品浏览用户 购买倾向模型名单	库存提醒、支付提醒、必要时价格激励 强化筛选、推荐排序、商品对比信息 突出售后、品牌信任、分期和保障服务 用作营销触达人群池，再按预算排序

模型分数适合做运营排序，不等同于促销干预效果。



购物车转化深化

从问题到数据，再到模型和业务结论

- ▶ 用户-月份模型刻画整体购买倾向，但时间粒度较粗。
- ▶ 漏斗中最有业务价值的一段是 cart-to-purchase。
- ▶ 当前数据集正好包含 view、cart、purchase 行为链路。
- ▶ 新任务：首次加购前/加购时可见信息，预测后续是否购买。
- ▶ 这比“当月行为预测当月购买”更能避免时间口径问题。

观察点前移到首次加购时刻，预测口径更接近实际触达场景。

项目	定义
样本单位	user_session
入样条件	session 内至少出现一次 cart
观察点	session 的首次 cart 时刻
主标签	首次 cart 后, session 内是否发生任意 purchase
辅助标签	首次 cart 的商品后续是否被 purchase
划分方式	10-11 月训练, 12 月测试

模型只看首次加购前后的可用信息, 用 12 月数据检验跨月泛化。



- ▶ 扫描三个月全量 177,493,621 条日志。
- ▶ 按 user_id 进行 1/20 确定性抽样，处理 8,879,159 条行为。
- ▶ 维护 session_state 字典，不保存原始明细。
- ▶ 每个 session 只保留首次 cart 前统计、首次 cart 信息和后续购买标签。
- ▶ 最终得到 216,713 个加购 session 样本，样本构造耗时约 7.76 分钟。

跨 chunk 维护 session 状态，是这部分工程实现的关键。

指标	数值
12 月测试样本	99,323
测试集购买率	48.12%
Precision	48.67%
Recall	97.13%
F1	0.648

- ▶ 分类阈值用于形成候选池。
- ▶ 高意向 session 的排序质量更接近营销场景。
- ▶ TopK 和 Lift 用于衡量有限预算下的触达效率。

高召回率适合扩大候选池，TopK 排序用于确定优先触达人群。


购物车转化预测 Lift@K



用户池	Precision	Lift
Top 1%	66.67%	1.39
Top 5%	61.54%	1.28
Top 10%	60.22%	1.25
Top 20%	58.31%	1.21

Top 10% 高分 session 的真实购买率达到 60.22%，明显高于 12 月整体购买率。

购物车转化模型特征重要性



- ▶ 首次 cart 前 session 持续时间影响最大。
- ▶ 首次加购价格和浏览商品范围提供额外信号。
- ▶ 加购小时、商品此前浏览次数也能帮助排序。

模型主要借助加购前停留、价格和浏览范围判断自然转化可能性。

- ▶ 高预测分数表示更可能自然购买，不等于最需要发券。
- ▶ 高自然转化用户：适合库存提醒、支付提醒、服务保障。
- ▶ 低自然转化但高价格 session：更接近召回候选池。
- ▶ 本文识别到 5,545 个“低自然转化概率 + 高加购价格” session。
- ▶ 数据没有优惠券、曝光、库存和物流字段，因此不做促销因果解释。

高分表示自然转化可能高，不代表发券一定有效。



结论

从问题到数据，再到模型和业务结论

1. 三个月 1.77 亿条日志呈现明显的浏览、加购、购买漏斗，购买行为相对稀疏。
2. 11 月和 12 月带来更大行为规模，但转化效率不能只靠流量判断。
3. 销售额集中在消费电子、家电相关品类和 200-1000 的主力价格带。
4. 用户-月份模型说明加购是强购买信号，但更适合解释购买倾向。
5. 购物车模型用首次加购前信息做跨月测试，Top 10% 高分 session 真实购买率为 60.22%。

从行为日志到漏斗和排序结果，分析对象始终围绕消费路径展开。

建议

- ▶ 对加购用户按自然转化概率分层触达
- ▶ 促销期同时监控流量、加购和支付转化
- ▶ 对核心品类优化库存、价格带和售后信息
- ▶ 改进 unknown 品类和品牌的信息治理

不足

- ▶ 唯一用户漏斗采用抽样估计
- ▶ 数据缺少曝光、优惠、库存和物流字段
- ▶ 月度模型仍是购买倾向识别口径
- ▶ 后续可加入滚动窗口、树模型和序列特征

运营重点落在加购后的支付转化，同时需要注意字段缺失限制。



- ▶ 数据处理：直接扫描三个月压缩日志，保留全量行为规模。
- ▶ 统计口径：区分事件数、用户数、抽样估计和 session 样本。
- ▶ 模型评估：购物车模型采用 10-11 月训练、12 月测试。
- ▶ 结果解释：同时给出描述性图表、逻辑回归系数和 TopK/Lift。
- ▶ 解释边界：不把相关性解释为促销因果效果。

口径一致、跨月验证和解释边界，是本分析的主要支撑。

谢谢!

欢迎老师和同学批评指正

成员分工

- ▶ 杨大权：主要负责原始数据采集、前期数据处理与基础清洗，以及课堂汇报主讲。
- ▶ 图力格尔：主要负责分析思路设计、统计分析与机器学习建模、图表整理，以及报告与 PPT 撰写。