



中国科学技术大学
University of Science and Technology of China

基于电商用户行为大数据的消费转化漏斗与购买预测分析

报告人：图力格尔

Python 经济大数据分析课程期末展示

2026 年 5 月 26 日



- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化

- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化
- 8 结论

- ▶ 电商平台记录了用户从浏览、加购到购买的完整消费路径。
- ▶ 用户行为日志天然具有经济含义：消费意愿、促销响应、品类偏好、品牌选择。
- ▶ 原始数据达到亿级记录，适合展示 Python 分块处理、聚合分析和机器学习建模。
- ▶ 研究目标不是只画统计图，而是回答“哪里流失、什么卖得好、谁更可能购买”。



1. 三个月内浏览、加购、购买的总体行为结构如何？
2. 10 月、11 月、12 月之间是否存在促销季和年末消费差异？
3. 哪些品类、品牌和价格区间贡献了主要交易额？
4. 能否利用用户行为特征预测其是否发生购买？



- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化
- 8 结论

层面	指标	作用
规模 转化	浏览、加购、购买、金额 浏览到加购、浏览到购买、 加购到购买	衡量平台整体活跃和交易规模 判断用户在哪个环节流失
结构 预测	品类、品牌、价格区间 Precision、Recall、F1、特征 系数	找到主要交易来源 识别潜在购买用户

项目	数值
数据来源	Kaggle 电商行为数据集
时间范围	2019-10 至 2019-12
文件形态	csv.gz / csv.zip
总记录数	177,493,621
分块大小	每块 1,000,000 行
本地处理耗时	约 22.7 分钟



- ▶ 事件口径：直接统计每条日志，用于浏览量、加购量、购买量和销售额。
- ▶ 用户口径：对 `user_id` 去重，用于漏斗和用户购买倾向识别。
- ▶ 全量事件统计保留 1.77 亿条日志的信息。
- ▶ 唯一用户漏斗采用 `user_id` 固定取模抽样估计，避免本地内存压力。
- ▶ 报告中明确区分“事件数”和“估计唯一用户数”，避免口径混用。

数据处理

- ▶ 压缩 CSV 分块读取
- ▶ 时间、价格、品类、品牌清洗
- ▶ 日、月、小时维度聚合
- ▶ 品类、品牌、价格区间统计

建模分析

- ▶ 用户-月份特征表
- ▶ 确定性用户抽样
- ▶ 逻辑回归购买预测
- ▶ 混淆矩阵与特征解释

```
reader = pd.read_csv(file_path, usecols=usecols,
                     chunksize=1_000_000,
                     compression="infer")

for chunk in reader:
    chunk["event_time"] = pd.to_datetime(
        chunk["event_time"], utc=True, errors="coerce"
    )
    chunk["month"] = chunk["event_time"].dt.strftime("%Y-%m")
    chunk["is_purchase"] = (chunk["event_type"] == "purchase")
```

每次只处理 100 万行，保留聚合结果和用户抽样特征，不长期保存原始明细。

- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化
- 8 结论

三个月用户行为事件量



- ▶ 浏览：167,321,576 次
- ▶ 加购：7,350,209 次
- ▶ 购买：2,821,836 次
- ▶ 购买金额：849,329,221.91


月份	浏览	加购	购买
2019-10	40,779,399	926,516	742,849
2019-11	63,556,110	3,028,930	916,939
2019-12	62,986,067	3,394,763	1,162,048

11 月和 12 月的流量与购买量明显高于 10 月，但流量增长并不自动等于转化效率提升。


行为	峰值小时	峰值事件数
浏览	16 点	11,564,432
加购	8 点	495,343
购买	9 点	211,140

- ▶ 浏览更像信息搜索和比较。
- ▶ 加购与购买更接近明确消费动作。
- ▶ 推荐曝光、购物车提醒和支付激励可以分时段设计。

三个月日度行为变化



各月加购到购买转化率




- ▶ 10 月购买规模较小，但加购到购买比例较高。
- ▶ 11 月流量和加购明显放大，转化效率被摊薄。
- ▶ 12 月购买量继续上升，年末消费需求更强。



- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化
- 8 结论

转化漏斗估计用户规模



阶段	估计用户数	占比
浏览	7,853,880	100.00%
加购	1,711,640	21.79%
购买	1,045,680	13.31%




- ▶ 浏览到加购：反映商品匹配、搜索推荐和详情页质量。
- ▶ 加购到购买：反映价格、促销、库存、配送和支付体验。
- ▶ 加购未购买用户已经表现出较强意向，是平台二次触达的重点对象。
- ▶ 促销期不应只看访问峰值，还要看购物车沉淀后的支付转化。




- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌**
- 6 购买预测
- 7 购物车转化深化
- 8 结论**

销售额最高的品类 Top 12



销售额最高的品牌 Top 12





- ▶ 手机、灯具工具、耳机、钟表、电视和家电贡献主要交易额。
- ▶ Apple 购买次数低于 Samsung，但销售额更高，体现高客单价特征。
- ▶ Samsung 购买次数最高，说明其覆盖更广泛的交易需求。
- ▶ unknown 品类和品牌占比不低，实际业务中需要改进商品信息治理。

价格区间	购买金额	金额占比
500-1000	268,103,353.39	31.57%
200-500	233,270,380.69	27.47%
1000-5000	194,988,617.34	22.96%
100-200	113,879,642.68	13.41%

中低价商品贡献交易频次，高价商品贡献销售额，需要分别管理。

- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化
- 8 结论

预测目标

以用户-月份为样本，预测用户当月是否发生购买。

输入特征

总行为次数、浏览次数、加购次数、会话数、活跃天数、浏览商品数、浏览品类数、浏览品牌数、平均价格、最高价格。

模型

使用 NumPy 实现逻辑回归，并对正样本设置权重以缓解类别不平衡。




- ▶ 样本单位：用户-月份。
- ▶ 标签：当月是否至少发生一次购买。
- ▶ 特征：当月行为强度、会话数、活跃天数、商品/品类/品牌范围、价格偏好。
- ▶ 当前模型适合识别高购买倾向用户。
- ▶ 更严格的实时预测应使用“前期行为预测后期购买”的时间切分。

指标	数值
测试集样本	50,000
正样本比例	11.43%
Accuracy	89.95%
Precision	53.68%
Recall	85.49%
F1	0.659

购买预测模型混淆矩阵

	Pred 0	Pred 1
True 0	TN 40,105	FP 4,201
True 1	FN 826	TP 4,868

购买预测模型特征重要性



- ▶ 加购次数是最强购买意图信号。
- ▶ 总行为次数和会话数反映用户活跃程度。
- ▶ 浏览范围过宽可能意味着仍在比较，购买确定性下降。

用户信号	可采取动作
多次加购未购买 浏览范围广但未加购 高价商品浏览用户 购买倾向模型名单	库存提醒、支付提醒、必要时价格激励 强化筛选、推荐排序、商品对比信息 突出售后、品牌信任、分期和保障服务 用作营销触达人群池，再按预算排序

- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化

- 8 结论



- ▶ 原用户-月份模型适合识别购买倾向，但不是严格实时预测。
- ▶ 漏斗中最有业务价值的一段是 cart-to-purchase。
- ▶ 当前数据集正好包含 view、cart、purchase 行为链路。
- ▶ 新任务：首次加购前/加购时可见信息，预测后续是否购买。
- ▶ 这比“当月行为预测当月购买”更能避免时间口径问题。

项目	定义
样本单位	user_session
入样条件	session 内至少出现一次 cart
观察点	session 的首次 cart 时刻
主标签	首次 cart 后, session 内是否发生任意 purchase
辅助标签	首次 cart 的商品后续是否被 purchase
划分方式	10-11 月训练, 12 月测试



- ▶ 扫描三个月全量 177,493,621 条日志。
- ▶ 按 user_id 进行 1/20 确定性抽样，处理 8,879,159 条行为。
- ▶ 维护 session_state 字典，不保存原始明细。
- ▶ 每个 session 只保留首次 cart 前统计、首次 cart 信息和后续购买标签。
- ▶ 最终得到 216,713 个加购 session 样本，样本构造耗时约 7.76 分钟。

指标	数值
12 月测试样本	99,323
测试集购买率	48.12%
Precision	48.67%
Recall	97.13%
F1	0.648

- ▶ 分类阈值不是核心。
- ▶ 更重要的是高意向 session 的排序能力。
- ▶ 因此重点看 TopK 和 Lift。




购物车转化预测 Lift@K



用户池	Precision	Lift
Top 1%	66.67%	1.39
Top 5%	61.54%	1.28
Top 10%	60.22%	1.25
Top 20%	58.31%	1.21

购物车转化模型特征重要性



- ▶ 首次 cart 前 session 持续时间影响最大。
- ▶ 首次加购价格和浏览商品范围提供额外信号。
- ▶ 加购小时、商品此前浏览次数也能帮助排序。



- ▶ 高预测分数表示更可能自然购买，不等于最需要发券。
- ▶ 高自然转化用户：适合库存提醒、支付提醒、服务保障。
- ▶ 低自然转化但高价格 session：更接近召回候选池。
- ▶ 本文识别到 5,545 个“低自然转化概率 + 高加购价格” session。
- ▶ 数据没有优惠券、曝光、库存和物流字段，因此不做促销因果解释。



- 1 研究问题
- 2 数据与方法
- 3 行为结构
- 4 转化漏斗
- 5 品类与品牌
- 6 购买预测
- 7 购物车转化深化



1. 三个月 1.77 亿条日志呈现明显浏览、加购、购买漏斗。
2. 11 月和 12 月行为规模较大，但转化效率需要单独监控。
3. 消费电子和家电相关品类贡献主要销售额。
4. 月度模型识别购买倾向，购物车模型进一步预测首次加购后的 session 转化。
5. 购物车转化模型 Top 10% 高分 session 真实购买率为 60.22%，Lift 为 1.25。



建议

- ▶ 对加购未购买用户重点触达
- ▶ 促销期同时关注流量和支付转化
- ▶ 对高销售额品类优化库存和价格带

不足

- ▶ 唯一用户漏斗采用抽样估计
- ▶ 模型尚未严格拆分购买前后行为
- ▶ 后续可尝试树模型和序列模型



- ▶ Python 脚本化：从原始压缩文件到图表和模型结果可复现。
- ▶ Pandas：分块读取、清洗、分组、透视和特征聚合。
- ▶ NumPy：逻辑回归的矩阵计算和评价指标计算。
- ▶ 可视化：将亿级日志压缩为行为漏斗、时间变化和结构图。
- ▶ 机器学习：将描述性分析推进到潜在购买用户识别。



谢谢!